

T.C.

GEBZE TEKNİK ÜNİVERSİTESİ

Bilgisayar Mühendisliği Bölümü

**DERİN ÖĞRENME
ARACILIĞIYLA RESİMLERİN
RESSAMLARININ TAHMİNİ**

Berkay Bakışoğlu

Danışman

Dr. Burcu Yılmaz

**Haziran, 2021 Gebze,
KOCAELİ**

T.C.

GEBZE TEKNİK ÜNİVERSİTESİ

Bilgisayar Mühendisliği Bölümü

**DERİN ÖĞRENME
ARACILIĞIYLA RESİMLERİN
RESSAMLARININ TAHMİNİ**

Berkay Bakışoğlu

Danışman

Dr. Burcu Yılmaz

**Haziran, 2021 Gebze,
KOCAELİ**

Bu çalışma 18/06/2021 tarihinde aşağıdaki jüri tarafından Bilgisayar Mühendisliği Bölümü’nde Lisans Bitirme Projesi olarak kabul edilmiştir.

Bitirme Projesi Jürisi

Danışman Adı	Burcu Yılmaz	
Üniversite	Gebze Teknik Üniversitesi	
Fakülte	Mühendislik Fakültesi	

Jüri Adı	Yakup Genç	
Üniversite	Gebze Teknik Üniversitesi	
Fakülte	Mühendislik Fakültesi	

ÖNSÖZ

Bu raporun hazırlanmasında emeği geçenlere, raporun son halini almasında yol gösterici olan sayın Dr. Burcu Yılmaz hocama ve bu çalışmayı destekleyen Gebze Teknik Üniversitesi'ne içten teşekkürlerimi sunarım.

Ayrıca eğitimim süresince bana her konuda tam destek veren aileme ve bana hayatlarıyla örnek olan tüm hocalarıma saygı ve sevgilerimi sunarım.

Haziran,2021

Berkay Bakışoğlu

İÇİNDEKİLER

ÖNSÖZ	4
İÇİNDEKİLER.....	5
ŞEKİL TABLOSU.....	6
KISALTMA LİSTESİ	7
ÖZET	8
SUMMARY	9
1)GİRİŞ.....	10
2)YÖNTEM.....	12
3)DENEYLER VE BULGULAR.....	17
1)AĞIRLIKSIZ EĞİTİLEN MODEL.....	17
2)ÖĞRENME TRANSFERİ YAPILAN MODEL	19
4)SONUÇ	24
KAYNAKLAR.....	28

ŞEKİL TABLOSU

ŞEKİL 1.1 Makine Öğrenmesi ve Derin Öğrenme Karşılaştırması	10
ŞEKİL 2.1 Görüntülerin Dijital Ortamda Temsili	12
ŞEKİL 2.2 Evrişim Katmanı İşlem Örneği	12
ŞEKİL 2.3 Havuzlama Katmanı Örneği	13
ŞEKİL 2.4 Bir Resimden Çıkartılan Parçalar	14
ŞEKİL 2.5 Bütün Halinde Resim	15
ŞEKİL 3.1 Yalnızca Parçalarla Eğitilmiş Başlangıç Modeli	17
ŞEKİL 3.2 Yalnızca Parçalarla Eğitilmiş Başlangıç Modeli	17
ŞEKİL 3.3 Parçalar ve Bütünlerle Eğitilmiş Başlangıç Modeli	18
ŞEKİL 3.4 Parçalarla Eğitilmiş, Veri Arttırma Uygulanmış Model	18
ŞEKİL 3.5 Daha Uzun Veri Kesitleri Alan Modelin İsabet ve Kayıp Sonuçları	19
ŞEKİL 3.6 RESNET-50 Yapısı	20
ŞEKİL 3.7 Başlangıç Öğrenim Transferi Modeli	20
ŞEKİL 3.8 Yalnızca Parçalarla Eğitilmiş Öğrenme Transferi Başlangıç Modeli	20
ŞEKİL 4.1 Ağırlıkları Olmayan Model İçin Karmaşıklık Matrisi	24
ŞEKİL 4.2 Öğrenme Transferi Yapılan Model İçin Karmaşıklık Matrisi	25
ŞEKİL 4.3 Öğrenme Transferi Yapılan Model İçin Eğitim Sonuçları	25

KISALTMA LİSTESİ

CNN	: Convolutional Neural Network (Evrişimli Sinir Ağı)
RESNET	: Residual Neural Network (Artık Sinir Ağı)

ÖZET

Bu projenin amacı, bir resmi veya bu resmin parçasını kullanarak, bu resmin ressamını tahmin etmektir.

Tarihin belirli dönemlerinden seçilen ressamların resimleri, birçok açıdan benzerlik taşımakta olmasına rağmen, ressamların farklı stilleri ve fırça darbeleri resimleri değiştirmektedir. Buna göre bu projede kullanmak üzere seçilen resimler, iki farklı şekilde, model eğitimi için kullanılmıştır. Bunların ilki, bir bütün resmin dört parçaya bölünmüş şekli, ikincisi ise aynı resmin bütün halidir. Bu şekilde modelin fırça darbelerini tanıması hedeflenmiştir.

Resim dosyaları, derin öğrenme modeline uygun hale getirmek için ön işlemden geçmiş, boyutları öğrenme transferi modelinde kullanılacak olan 224x224 boyutuna getirilmiştir. 21 ressamın 60'ar adet resmi test için kullanılmıştır. Bütün halinde olan resimler ressam başına 300, parçalar halinde ise 1200 resimdir. Buna göre 1260 resim test için, 31600 modelin eğitimi için kullanılmıştır.

Model eğitimi için RESNET-50 modeli seçilmiş ve öğrenme transferi için yapılan deneyde “imagenet” ağırlıkları kullanılmıştır.

Eğitimler sonucunda test verileri kullanarak tahminler ve olasılıklar elde edilmiş, bir karmaşıklık matrisi oluşturularak modelin verdiği kararlar gözlenmiştir.

SUMMARY

The aim of this project is to predict the artist of this painting, using a painting or part of painting..

Although the paintings of the painters selected from certain periods of history are similar in many respects, the different styles and brush strokes of the painters change the paintings. Accordingly, the pictures chosen for use in this project were used in model training in two different ways. The first of these is the form of a whole picture divided into four parts, and the second is the whole version of the same picture. In this way, it is aimed that the model recognizes the brush strokes.

The picture files were pre-processed to make them suitable for the deep learning model, and their dimensions were reduced to 224x224, which will be used in the learning transfer model. 60 pictures of 21 painters were used for the test. Whole paintings are 300 per artist and 1200 in parts. Accordingly, 1260 images were used for testing and 31600 for training the model.

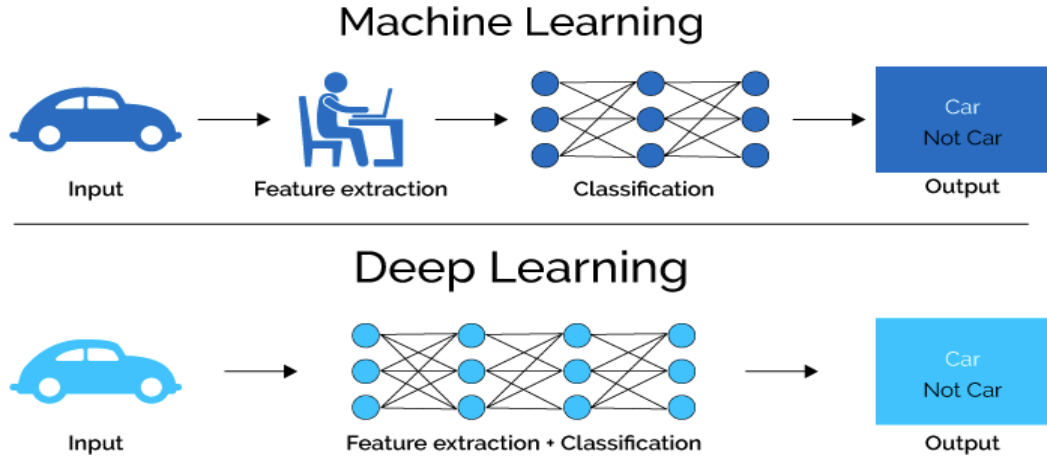
The RESNET-50 model was chosen for model training and imagenet weights were used in the transfer learning experiment .

As a result of the trainings, predictions and probabilities were obtained using test data, and the decisions made by the model were observed by creating a complexity matrix.

1)GİRİŞ

Çağlar boyunca sanat toplumun en önemli parçalarından birisi olmuştur. Sanatın en önemli parçalarından birisi ise, ilk insanın ortaya çıkışından itibaren insanın hayatında bulunmaya başlayan resim dalıdır. Mağara duvarlarına çizilerek başlanan bu dalda, insanlar daima çalışmalar yapmış, kendisini geliştirmeye çalışmıştır. Her ressam kendisinden önceki ressamı ve resimlerini gözlemleyerek onlardan esinlenmiş, bu resimlerden daha güzel çalışmalar ortaya çıkarmaya çalışmıştır. Bunun sonucunda, bazı ressamın ufak farklılıklar ve fırça stilleri dışında, birbirinden ayırt edilmesi gitgide zorlaşmıştır. Bilgisayarların ve derin öğrenme tekniklerinin gücünü kullanarak, resimlerin sınıflandırılması amaçlanmış, kendi resimlerinin hangi ressama yakın-sadığını bilmek isteyen ressamlar için bir kolaylık oluşturulmaya çalışılmıştır.

Bir resim dosyasını sınıflandırma işlemi, genellikle makine öğrenmesi veya derin öğrenme ile gerçekleştirilmektedir.[1]



ŞEKİL 1.1 Makine Öğrenmesi ve Derin Öğrenme Karşılaştırması

Derin öğrenme veya diğer adıyla sinir ağları, özellik çıkarılmadan, etiketlenmiş ham veriyi girdi olarak kabul ederek öğrenen yapay zekâ alt dalıdır. Modele verilen Veriyi iterasyonlar uygulayarak, iterasyonlar sırasında parametreleri düzenleyerek öğrenimi sağlayan bir yaklaşımdır.


Resim sınıflandırmada, bir giriş katmanına gönderilen resim, bilgisayarın onu işleyebilmesini sağlayan sayı değerlerine çevrilir. Daha sonra bu katmandan gizli katmanlara gönderilir, gizli katmanların yaptığı hesaplamaların sonucunu çıkış katmanına iletir ve bu katman, girmiş olduğumuz verinin sonucunun tahminini verir.

Gelişen teknoloji ile birlikte, derin öğrenme ile resim sınıflandırma işlemleri artıp farklı dallara yayılmıştır. Resimdeki objeleri tanıma konusunda %90'a varan isabet oranları yakalanmıştır.[2]

Bu çalışmada, resim sınıflandırma konusunda iyi sonuçlar verdiği literatür araştırmaları sonucunda gözlemlenen CNN derin öğrenme algoritmasını temel alan, bu alanda geçmiş yıllarda başarı sağlamış RESNET-50 mimarisi kullanılmıştır.

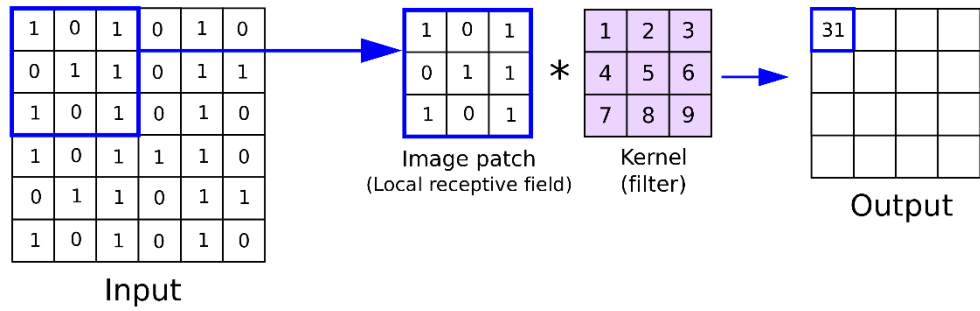
2)YÖNTEM

CNN algoritması, genellikle görüntü işlemede kullanılan ve girdi olarak görüntüleri kullanan ve bu görüntülerden özellik çıkarıp sınıflandırma yapan katmanlardan oluşan bir algoritmadır. Dijital ortamda resim, belirli renk değerlerini temsil eden sayı değerleriyle oluşturulur.




ŞEKİL 2.1 Görüntülerin Dijital Ortamda Temsili

Bu katmanlardan özellik çıkarımı için, evrişim katmanları kullanılır. Görüntü matrisi üzerinde belirli bir boyutta parçalar alınarak, bu parçalara filtreleme uygulayarak özelliklerini çıkartır.



ŞEKİL 2.2 Evrişim Katmanı İşlem Örneği




ŞEKİL 2.3 Havuzlama Katmanı Örneği

Havuzlama katmanı ise, yine bir görüntü matrisine filtre uygulayarak, görüntüyü sadeleştirmeyi amaçlar.

Literatürdeki çalışmalar araştırılmış[3][4][5],ve bu yöntemleri temel alan ve bunların kombinasyonlarıyla oluşturulan RESNET-50 [6] ağı, projede kullanılmıştır. Bu modeli temel alan iki farklı eğitim yapılmıştır.

Model eğitimleri için kullanılan veriseti 21 ressamın 1024x1024 boyutunda 300 resminden oluşurken,iki farklı şekilde kullanılmıştır.Modellerin ilk eğitimi,resimlerin 4 parçaya bölünmüş şekliyle yapılırken,ikinci eğitimi resimlerin tamamı kullanılarak yapılmıştır.Bu işlemin amacı,modelle uygun hale getirilen resimlerin çözünürlük değişiminden kaynaklanan veri kaybını çözmek,bunun yanında resmin data detaylı halini,ressamların fırça darbelerini tanımasını sağlamaktır.

İkinci eğitim için ise bu modellerin üzerine,resimlerin bütün olarak hali kullanılmıştır.



ŞEKİL 2.4 Bir Resimden Çıkartılan Parçalar



ŞEKİL 2.5 Bütün Halinde Resim

Modellerin eğitiminden önce, Keras[7] kütüphanesinin fonksiyonları kullanılarak veri setindeki resimler yüklenmiş, daha sonra bu görüntülere, dikey ve yatay dönüşüm, döndürme, kaydırma, kesit alma ve yakınlaştırma gibi veri artırma işlemleri uygulanarak, eğitim ve test setleri oluşturulmuştur. Test seti aynı zamanda doğrulama seti olarak da kullanılmıştır. Öğrenme oranı optimizasyonu için iyi sonuçlar verdiği gözlenen[8] ADAM algoritması kullanılmıştır.

İlk deney için kullanılan model, Keras kütüphanesi kullanılarak elde edilen RESNET-50 modelidir. Bu modelin üst katmanı, yani tahmin yapan katmanı çıkartılarak, bütün katmanlarının eğitilmesine izin verilmiş, bu katmanların sonucunda ulaşılan verilere düzleştirme uygulanmış, bu düzleştirilmiş veriler, kullanılan sınıflandırma sayısına göre yeni bir softmax katmanına gönderilmiştir. Parçalanmış verilerle eğitim, her iterasyonda tahmin edilecek verilerle test edilerek, en iyi sonuç alan model kaydedilmiştir. Daha sonra kaydedilen bu model, yine veri zenginleştirme işlemlerinden geçmiş resimlerin bütün halleri kullanılarak bir kez daha eğitilmiştir. Son olarak bu modelden tahminler alınarak,21 ressam için karmaşıklık matrisi oluşturulmuştur.

İkinci model ise öğrenme transferi ile oluşturulmuştur. Öğrenme transferi yapay öğrenme sistemlerinin eğitim aşamasıyla öğrendiği bilgiyi farklı veya benzer problem çözümlerinde kullanılmasını inceleyen öğrenme yaklaşımıdır.[9] Bu yöntem aracılığıyla daha önce oluşturulmuş ve büyük veri setleriyle eğitilmiş modellerden yararlanılarak, eğitim süresinde ve isabet oranında artış sağlanmaktadır. Özellik çıkarıcı olarak kullanılan önceden eğitilmiş modelin katmanları dondurularak, üzerine eklenen yeni katmanların, bu katmanlardan edindiği bilgileri öğrenmesine dayanır.


Buna göre ikinci model de ilk model gibi parçalanmış ve bütün halde olan resimleri ve bu resimlerin veri arttırma ile değiştirilmiş halleriyle eğitildi. RESNET-50 modelinin “Imagenet” yarışmasında edinilen ağırlıkları kullanılarak, katmanları dondurularak eğitim sırasında öğrenmesi engellendi. Bu modelin çıktı katmanı üzerine eklenen bir softmax katmanı ile, daha önceden eğitilmiş modelin çıkarım yapmasına ve tahminlerin bu katmanlardan gelen bilgiler üzerine yapılması sağlanmıştır.

Veri setinin ana kaynağı wikiArt[10]. Daha sonra bu veriler projenin ihtiyacına göre düzenlenmiştir.


3)DENEYLER VE BULGULAR

1)AĞIRLIKSIZ EĞİTİLEN MODEL

Başlangıç deneyleri için, veri seti 10 ressamın resimleriyle ve veri arttırma teknikleri kullanılmadan gerçekleştirildi. Öncelikli olarak model, yalnızca parçalanmış görüntüler, yalnızca bütün haldeki görüntüler ve iki veri seti birlikte olarak test edildi.



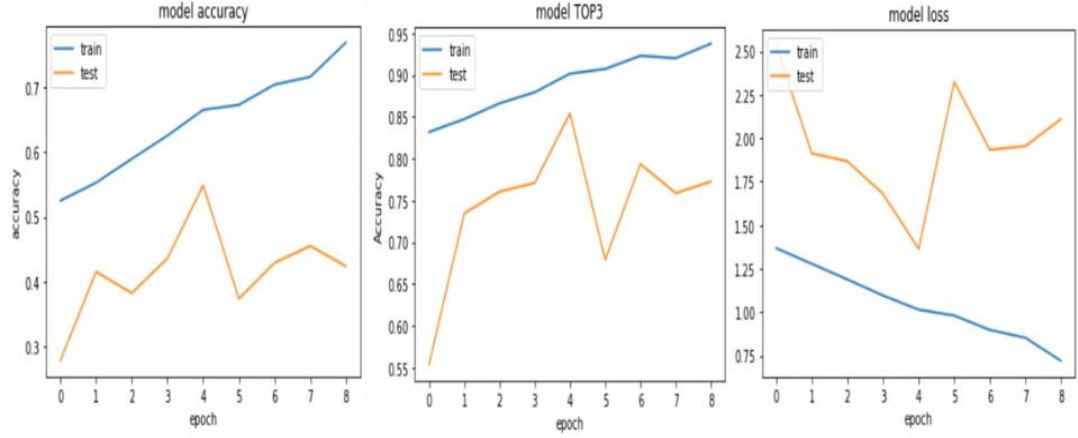
ŞEKİL 3.1 Yalnızca Parçalarla Eğitilmiş Başlangıç Modeli



ŞEKİL 3.2 Yalnızca Parçalarla Eğitilmiş Başlangıç Modeli

İki model arasında yapılan karşılaştırmalarda, parçalarla eğitilen modelin, resimlerin bütünüyle eğitilen modele göre isabet oranının çok düşük olduğu görüldü. Bu iki tekniğin


birleştirilmesinde olan değişimi gözlemlemek için test yapıldı.



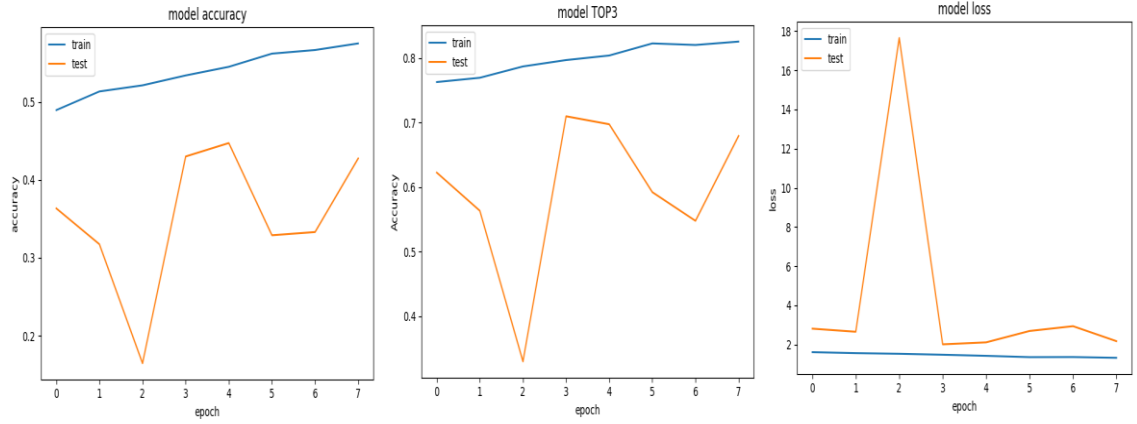
ŞEKİL 3.3 Parçalar ve Bütünlülerle Eğitilmiş Başlangıç Modeli

İki tekniğin birleşimi ile, modelin isabet oranında %5 e yakın bir isabet artışı sağlandı. Buna göre bu tekniği kullanmanın modelin eğitimi açısından daha yararlı olduğuna karar verildi.

Modellerin eğitim döngülerinin kısa sürdüğü ve bir süre sonra modelin aşırı uyum sağladığı tespit edildi. Makalede önerilen [11] yöntemlerden, dikey ve yatay döndürme, yakınlaştırma, rotasyon, dikey ve yatay kaydırma, kırpma işlemleri birlikte kullanılarak modelin aşırı öğrenmesini durdurma ve isabet değerini yükseltme amaçlandı. Veri seti 10 ressamdan 21 ressama çıkartılarak, modelin daha geniş bir sınıflandırma kabiliyetine sahip olması amaçlandı, bu sayede eğitime giren verilerde yüksek oranda artış sağlandı.



ŞEKİL 3.4 Parçalarla Eğitilmiş, Veri Arttırma Uygulanmış Model

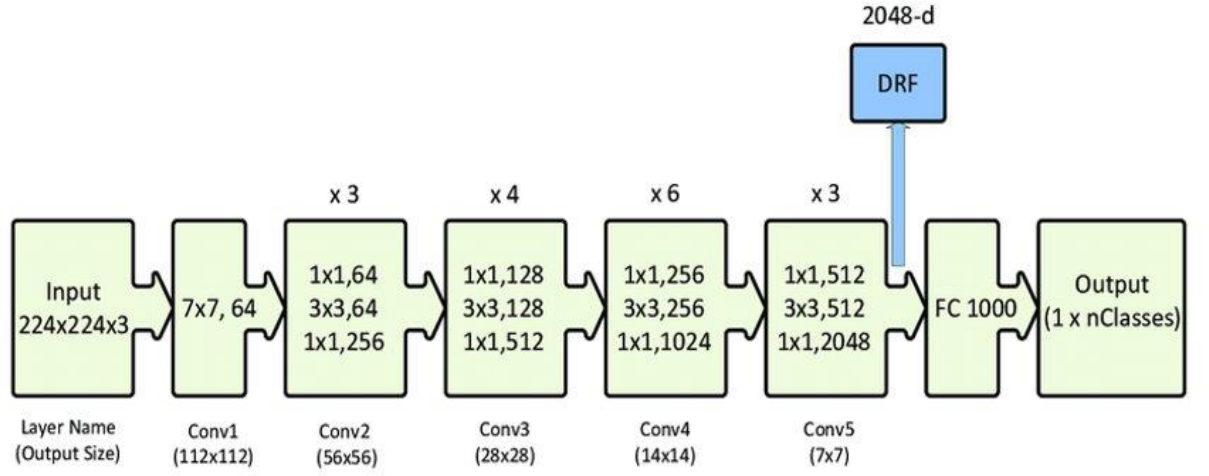


ŞEKİL 3.5 Daha Uzun Veri Kesitleri Alan Modelin İsabet ve Kayıp Sonuçları


Veri sayısının artırılmasıyla birlikte, sınıflandırılacak olan resim sayısının artmasıyla beklenen doğal düşüş, veri artırma yöntemleriyle desteklenerek en aza indirildi, modelin öğrenme aşamasının daha düzenli olması sağlandı ve modelin isabet oranında beklenen düşüşten daha yüksek bir isabet oranı ortaya çıkarıldı. Seçilen RESNET-50 modelinin yapısını değiştirmemek adına bu model üzerinde daha fazla işlem yapılmadı ve test için bu modelin bu şekilde uygulanmasına karar verildi.

2)ÖĞRENME TRANSFERİ YAPILAN MODEL


Öğrenme transferini gerçeklemek için, şekil 3.6’da gösterilen RESNET-50 model yapısının, bütün katmanları dondurularak gerçekleştirilecek eğitim sırasında öğrenim görmemesi, daha önce kullandığı bilgileri kullanması hedeflendi ve sınıflandırma yapmasını sağlayan conv5 bloğundan sonrası kesilerek, yerine sınıflandırma yapacak yeni bir katman eklenmesi sağlandı. Böylece bu modelin “Imagenet” yarışmasında kullanılmak için büyük bir veri setiyle eğitilen bir versiyonu, özellik çıkarımı yapmak için kullanıldı, daha sonra Keras kütüphanesinden ardışık bir model kullanılarak gerekli katmanlar üzerine eklendi.




ŞEKİL 3.6 RESNET-50 Yapısı



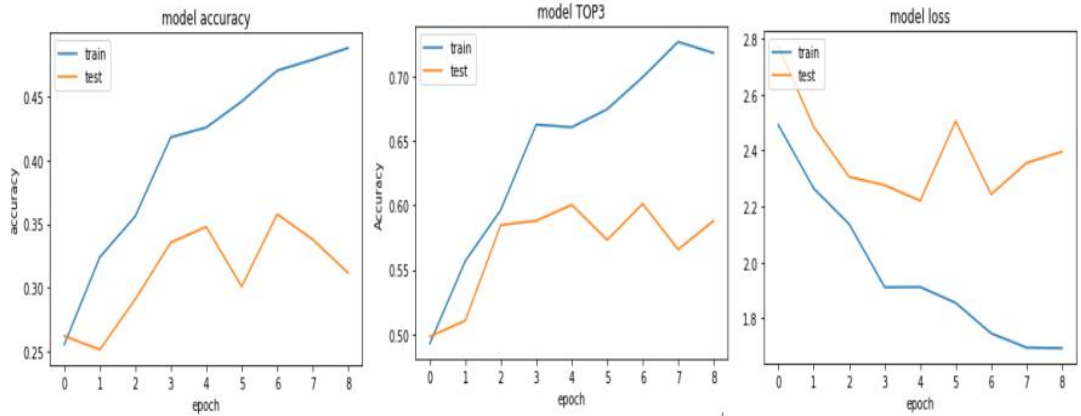
ŞEKİL 3.7 Başlangıç Öğrenim Transferi Modeli



ŞEKİL 3.8 Yalnızca Parçalarla Eğitilmiş Öğrenme Transferi Başlangıç Modeli




ŞEKİL 3.9 Yalnızca Bütünlerle Eğitilmiş Öğrenme Transferi Başlangıç Modeli




ŞEKİL 3.10 Parçalar ve Bütünlerle Eğitilmiş Öğrenme Transferi Başlangıç Modeli

Başlangıç veri seti ile eğitilen öğrenme transferi modeli de, ağırlıksız modelde olduğu gibi düşük sayıda veri olmasından ötürü çok erken aşırı uyum sağlamaya başladı. Tahminlerinde diğer modelden daha başarılı olsa da, aşırı uyumu engellemek için veri sayısı arttırılmalıydı.


Aynı zamanda öğrenme transferi tekniğinin farklı şekillerde uygulanması mümkündü. Bunun için modelin en spesifik özelliklerini çıkartan son bloktaki katmanlardan başlanarak, katmanların eğitilmesi üzerine testler yapıldı.



ŞEKİL 3.11 Son Katman Bloğu Eğitilmiş Öğrenme Transferi Modeli Yapısı




ŞEKİL 3.12 Son Katman Bloğu Parçalarla Eğitilmiş Öğrenme Transferi Model Eğitim Sonuçları




ŞEKİL 3.13 Son Katman Bloğu Parçalarla ve Bütünlerle Eğitilmiş Öğrenme Transferi Modeli

Bu deney sonucunda, bütün katman bloklarını dondurmak ile, en fazla detay içeren bloğu eğitmenin sonuçlarının birbirine çok yakın fakat daha isabetsiz olduğu görüldü.

Belirsizliği ortadan kaldıracırmek adına, birden fazla bloęu eğitmenin model için daha uygun olup olmadığı test edildi.



ŞEKİL 3.14 4. Ve 5. Katman Blokları Parçalarla Eğitilmiş Öğrenme Transferi Modeli




ŞEKİL 3.15 4. Ve 5.Katman Blokları Parçalarla ve Bütünlerle Eğitilmiş Öğrenme Transfer Modeli


Ağırlık içeren katmanların eğitilmesinin model üzerinde olumsuz etki yarattığı gözlemlendi. Buna göre modelin bütün katmanlarını dondurarak bir özellik çıkarıcı olarak kullanmanın yeni tahminler için en olumlu sonuç olduğuna karar verildi.

4)SONUÇ


Google Colabs üzerinden NVIDIA Tesla K80 GPU ile yapılan ağırlıksız modelin eğitimi yaklaşık 12 saat sürerken, öğrenme transferi gerçekleştirilen modelin eğitimi yaklaşık 8 saatte tamamlandı. Öğrenme transferinin eğitim süresini kısaltma hedefi göz önüne alındığında 3'te 1'lik bir zaman kazancı elde edildi. Keras kütüphanesinden checkpoint çağrısı kullanılarak, modelin eğitiminin en iyi sonuç verdiği durumda bitirildi. Eğitilen modellerin testleri yapıldı ve bu testler sonucunda karmaşıklık matrisleri ortaya çıkarıldı. Modellerin tahminleri değerlendirilirken, hem modelin en iyi tahmini, hem de en iyi 3 tahminini de göz önünde bulundurularak gerçek resimler için isabet oranları çıkartıldı.



ŞEKİL 4.1 Ağırlıkları Olmayan Model İçin Karmaşıklık Matrisi



ŞEKİL 4.2 Öğrenme Transferi Yapılan Model İçin Karmaşıklık Matrisi



ŞEKİL 4.3 Öğrenme Transferi Yapılan Model İçin Eğitim Sonuçları

Model	Top-1 İsabet	Top-3 İsabet
Ağırlıkları Olmayan Model	%42	%70
Öğrenme Transferi Gerçekleştirilen Model	%62	%82

Tablo 4.1 Gerçek Resimler ile Yapılan Test Sonuçları

Bu testin ardından, gerçek resimlerin döndürülmüş, kesilmiş gibi modifikasyona uğramış halleri kullanılarak yeni bir test yapıldı.

Model	Top-1 İsabet
Ağırlıkları Olmayan Model	%42
Öğrenme Transferi Gerçekleştirilen Model	%60

Tablo 4.2 Modifiye Resimler ile Yapılan Test Sonuçları

Testler sonucunda öğrenme transferi yapılan modelin, modifiye edilmiş verilerle yapılan testlerde isabet oranının düştüğü, daha önce eğitim görmemiş RESNET-50 yapısını kullanan modelin ise isabet oranını koruduğu gözlemlendi. Testler yapılmadan önce beklenen durum, öğrenme transferi modelinin daha etkili sonuç göstermesiydi. Yapılan testler sonucunda, bu durumun gerçekleştiği, 'imagenet' yarışmasında elde edilen bilgileri kullanarak, öğrenme transferi modelinin daha başarılı performans gösterdiği gözlemlendi. İki modelin tahmin yönelimleri göz önüne alındığında, tek bir modelden tahmin almak yerine, belirli bir algoritma içerisinde iki modelin tahminlerinin birleştirilmesi daha başarılı tahminlerde bulunarak geliştirilebilir. Bir başka yakın çalışma ile karşılaştırma yapıldığında, [12] hem sıfırdan eğitilen model için, hem de öğrenme transferi modelinin tahminlerinde benzer bir isabet oranı yakaladığı söylenebilir. Fakat diğer çalışmada kullanılan tahmin sistemi, resmin bir bütün olarak modelin girdisi olacağı yönündeydi. Bu çalışmada modelin resmin herhangi bir parçasından elde edeceği isabet oranının, diğer çalışmaya göre daha tutarlı ve isabetli olması beklenebilir. Proje öncesi belirlenen,

modellerin %40 ve üzeri top-1 tahmin başarısı, ve bir model için hedeflenen %70 top-3 başarısına iki modelde de ulaşıldı. Aynı zamanda veri setinin daha da genişletilmesi başarılı olma oranını arttırabilir. Bunların ışığında bu çalışma, geliştirmeye açık olarak kabul edilebilir.

KAYNAKLAR

- [1] S. Loussaief and A. Abdelkrim, "Machine learning framework for image classification,", *7th International Conference on Sciences of Electronics, Technologies of Information and Telecommunications (SETIT)*, 2016
- [2] *Imagenet Yarışma Sonuçları*[online],<https://paperswithcode.com/sota/image-classification-on-imagenet> [Ziyaret Tarihi:5 Mart 2021].
- [3] Johnson, J. *Neural Style Representations and the Large-Scale Classification of Artistic Style*. 1–10, 2016.
- [4] Mondal, K.. Categorization of artwork images based on painters using CNN. *Journal of Physics: Conference Series*, 1818(1), 2021.
- [5] Bar, Y., Levy, N., & Wolf, L. Classification of artistic styles using binarized features derived from a deep neural network. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 8925, 71–84, 2015.
- [6] He, K., Zhang, X., Ren, S., & Sun, J., Deep residual learning for image recognition. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2016
- [7] *Keras*[online]. <https://keras.io> [Ziyaret Tarihi: 1 Mart 2021].
- [8] Soydaner, A Comparison of Optimization Algorithms for Deep Learning. *International Journal of Pattern Recognition and Artificial Intelligence*, 34(13), 1–26,2020.
- [9] Fırıldak, K., & Talu, M. F, Evrişimsel Sinir Ağlarında Kullanılan Transfer Öğrenme Yaklaşımlarının İncelenmesi. *Anatolian Journal of Computer Science*, 4(2), 88–95.,2019.
- [10] *WikiArt*[online]. <https://www.wikiart.org/en/about>. [Ziyaret Tarihi: 1 Mart 2021].
- [11] Shorten, C., & Khoshgoftaar, T. M. A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 6(1). 2019.
- [12] Viswanathan, N. *Artist Identification with Convolutional Neural Networks*. 2–9.2017.